
1. ETT REGNIGT SVERIGE...
Vi behöver semester!

Kan vi förutsäga vilka hotellbokningar som riskerar att avbokas?



Problemet: Avbokningar skapar osäkerhet för hotellens planering



Målgruppen: Hotell som vill kunna identifiera riskbokningar i förväg



Målet: Identifiera bokningar med hög avbokningsrisk.



Avgränsning: Utvärdera avbokningsrisk – inte utveckla ett färdigt bokningssystem.

Vilken data har vi arbetat med?

Hotel Booking Demand Dataset · 2015–2017

119 390
historiska bokningar

32
ursprungliga kolumner

2
hotell i Portugal

Två hotelltyper

City Hotel · Stadshotell

Resort Hotel · Semesterhotell

Exempel på bokningsinformation

Ledtid · Rumstyp · Tidigare bokningar · Resebyrå

Målvariabel: is_canceled

0 = Inte avbokad · 1 = Avbokad

Hur förberedde vi datan?

Utforskande dataanalys - EDA

Vi undersökte avbokningsmönster, saknade värden och avvikande bokningar

Datarensning

Vi hanterade saknade värden och tog bort orimliga observationer

Förberedelse av variabler

Vi valde relevanta variabler, standardiserade numeriska värden och kodade kategorier

Tidsbaserad uppdelning

Vi delade upp datan i träning, validering och test utifrån tid

Modellen ska förutsäga framtida avbokningar – inte lära sig av framtiden

Tre modeller – ett mål: förutsäga avbokningar

Baseline

Använder lead_time

Flaggar de 20% med längst ledtid

Varför? Enkel referenspunkt

Regelbaserad modell

Logistic Regression

Använder flera bokningsvariabler

Rangordnar efter avbokningsrisk

Varför? Lättare att tolka

Enklare ML-modell

Random Forest

Använder flera bokningsvariabler

Fångar komplexa samband

Varför? Kan hitta mer komplexa mönster

Mer avancerad ML-modell

Alla tre metoderna jämförs genom att flagga 20% av bokningarna

Resultat – vilken modell fungerade bäst?

Hur utvärderade vi?

Precision@20%: Hur stor andel av de 20% flaggade bokningarna blev faktiskt avbokade?

Recall@20%: Hur stor andel av alla avbokningar lyckades vi hitta bland de flaggade bokningarna?

Tidsbaserat test: Modellerna utvärderades på senare bokningar än dem de tränades på

Modell	Precision@20%	Recall@20%
Baseline (lead_time)	50,81%	25,66 %
Logistic Regression	80,68%	40,75%
Random Forest	81,75 %	41,29%

Random Forest identifierade 921st fler avbokningar än Baseline – vid samma antal flaggade bokningar

Vad betyder resultaten för hotellet?

Identifiera högriskbokningar:

Modellen rangordnar bokningar efter uppskattad avbokningsrisk

Arbeta förebyggande:

Hotellet kan fokusera på de 20% med högst risk

Förbättra planering:

Riskbedömningarna kan ge stöd vid planering av beläggning och resurser

Stöd – inte facit:

En hög risk betyder inte att gästen säkert kommer att avboka

Modellen ska hjälpa personalen att fatta beslut – inte fatta besluten åt dem

DEMO



Hur tillförlitliga är våra förutsägelser?



Historisk data

Modellen har testats på bokningar från 2016 – inte på dagens hotellbokningar



Risk för dataläckage

Vissa variabler kan innehålla information som inte var känd vid bokningstillfället



Saknad ändringshistorik

Vi kan inte alltid veta hur bokningsuppgifterna såg ut när bokningen gjordes



Begränsad generaliserbarhet

Resultaten gäller vår testdata och kan inte automatiskt överföras till andra hotell

Modellen bör inte användas för automatiska beslut om enskilda gäster utan ytterligare validering

Slutsats

Kan vi förutsäga hotellavbokningar?



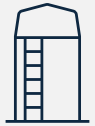
Vår rekommendation

Random Forest gav bäst resultat i vår slutliga jämförelse



Vad vi uppnådde

81,75% precision när vi flaggade de 20% mest riskfyllda bokningarna



Praktisk nytta

Modellen kan hjälpa hotell att prioritera uppföljning och planering



Nästa steg

Testa på nyare data och undersöka hur modellen fungerar i verklig hotelldrift

Maskininlärning kan förutsäga risk – men inte framtiden med säkerhet

ADEUS!

